

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN - ĐHQG TPHCM
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KỲ
NHẬP MÔN XỬ LÝ NGÔN NGỮ TỰ NHIÊN
**VIETNAMESE SPELLING
CHECKER**

Giảng viên hướng dẫn: Thầy Đinh Điền, thầy Nguyễn Hồng Bửu Long

Sinh viên:

Họ và tên	Mã số sinh viên	Lớp
Phan Huỳnh Minh Khôi	23127072	23CNTThuc1
Huỳnh Gia Bảo	23127154	23CNTThuc1
Nguyễn Đức Trí	23127541	23CNTThuc1

Hồ Chí Minh, 2026

VIETNAMESE SPELLING CHECKER

23CNTThuc1

Ngày 3 tháng 1 năm 2026

Mục lục

1	Nội dung đồ án	3
1.1	Giới thiệu đồ án	3
1.2	Ý nghĩa thực tiễn	3
1.3	Đầu vào - đầu ra của mô hình	3
2	Quy trình thực hiện	3
2.1	Xây dựng dataset	3
2.2	Tìm model phù hợp	4
2.3	Thực hiện fine-tune	4
2.3.1	Phần cứng	4
2.3.2	Kỹ thuật sử dụng	4
2.3.3	Các tham số khi fine-tune	5
3	Kết quả và đánh giá	5
3.1	Kết quả quá trình fine-tune	5
3.2	Đánh giá mô hình sau fine-tune	5

1 Nội dung đề án

1.1 Giới thiệu đề án

Nhóm có nhiệm vụ xây dựng một mô hình Vietnamese Spelling Checker - mô hình sửa lỗi chính tả tiếng Việt trong văn bản, bằng cách tìm một mô hình phù hợp rồi fine-tune.

Về mặt chức năng, mô hình này tương tự như các công cụ kiểm tra chính tả và ngữ pháp phổ biến như Grammarly, tuy nhiên được thiết kế chuyên biệt cho ngôn ngữ tiếng Việt, với đầy đủ các đặc trưng về dấu thanh, dấu phụ và cấu trúc âm tiết.

1.2 Ý nghĩa thực tiễn

Tiếng Việt là một ngôn ngữ rất dễ mắc lỗi chính tả (một cách cố ý hoặc vô ý), bởi nhiều nguyên nhân: có nhiều âm viết khác nhau nhưng phát âm khá giống nhau (ví dụ: x/s, ng/n, ...), nhiều cách viết tắt (ko = không, cs = có, ...), và nhiều nguyên nhân khác.

Vì vậy, mô hình có thể hỗ trợ người dùng trong nhiều tác vụ, ví dụ trong học tập và công việc, đặc biệt trong soạn thảo văn bản, báo cáo, email và nội dung số.

1.3 Đầu vào - đầu ra của mô hình

Đầu vào và đầu ra của mô hình:

- Đầu vào: Văn bản có thể chứa lỗi chính tả.
- Đầu ra: Văn bản đã được phát hiện và sửa lỗi chính tả

Ví dụ: “Tôi đonq tình” → “Tôi đồng tình”

2 Quy trình thực hiện

2.1 Xây dựng dataset

Dataset được xây dựng dựa trên sách *Quốc Triều Chánh Biên Toát Yếu* của tác giả *Cao Xuân Dục*, bao gồm 14.230 cặp câu (input, output) với độ dài mỗi câu khoảng từ **10 - 15 từ**:

- *Câu sai chính tả (input)*: Sử dụng **công cụ PPOCRLabel** để trích xuất các dòng văn bản từ sách. Ở bước này, văn bản được trích xuất thường có nhiều lỗi chính tả, được sử dụng để làm input.
- *Câu đúng chính tả (output)*: Sử dụng **thuật toán Levenshtein** để đóng hàng giữa những câu sai chính tả và những câu đúng trong sách. Đồng thời, để tăng độ chính xác và tin cậy, dataset còn được kiểm tra và chỉnh sửa thủ công nếu có sai sót.

Một vài đặc trưng lỗi chính tả có trong dataset:

- *Sai dấu*: "chiếc thuyền" → "chiếc thuyền"
- *Thiếu dấu*: "dong tinh" → "đồng tình"
- *Gộp từ sai*: "Nghe-An" → "Nghệ An"
- *Thiếu từ, thiếu kí tự, ...*

Phân chia dataset:

Tập dữ liệu	Tỷ lệ	Số lượng mẫu
Train	80%	11.384
Validation	10%	1.423
Test	10%	1.423

2.2 Tìm model phù hợp

Model được sử dụng trong đề án này là *ViT5 (bản base)* của *VietAI*. Truy cập model tại: [Link](#). Tổng quan về mô hình:

- Có cấu trúc **Encoder - Decoder**: có khả năng sinh chuỗi mới từ chuỗi cũ, phù hợp cho việc sửa lỗi (sinh ra chuỗi mới đã được sửa lỗi).
- Có khoảng **220M tham số**: vì kích thước của dataset khá nhỏ, 220M là số lượng tham số vừa đủ để mô hình tránh khỏi việc bị overfitting.

2.3 Thực hiện fine-tune

2.3.1 Phần cứng

Mô hình được fine-tune trên **Google Colab** với **GPU T4** gồm **16GB VRAM**.

2.3.2 Kỹ thuật sử dụng

- *Warmup Scheduler*: giúp ổn định quá trình fine-tune bằng cách cho phép mô hình điều chỉnh learning rate từ từ.
- *Early Stopping (patience = 2)*: giúp mô hình tránh tình trạng overfitting. Nếu sau 2 epoch liên tiếp mà validation loss không giảm, thì mô hình sẽ ngừng huấn luyện.

2.3.3 Các tham số khi fine-tune

$$\mathcal{H}_{\text{Fine-tune}} = \begin{cases} \text{Learning Rate} & = 1 \times 10^{-4} \\ \text{Optimizer} & = \text{AdamW (8-bit)} \\ \text{Warmup Steps} & = 1000 \\ \text{Training Steps} & = 9000 \\ \text{Batch Size} & = 16 \\ \text{Num. Epochs} & = 14 \end{cases}$$

3 Kết quả và đánh giá

3.1 Kết quả quá trình fine-tune

- Nhóm đã dự tính sẽ train model với 14 epoch. Trong quá trình huấn luyện có theo dõi validation loss để áp dụng Early Stopping (với patience bằng 2 epoch) - tức sẽ tự động ngừng train nếu sau 2 epoch liên tiếp mà validation loss không giảm.
- Kết quả khá bất ngờ vì chỉ sau 1 epoch, model đã học được tới độ lỗi cực tiểu (tức validation loss từ epoch 2 có xu hướng tăng). Lí giải cho điều này, có lẽ vì mô hình ViT5 mạnh hơn nhóm dự tính, nó đã hiểu nghĩa tiếng Việt khá tốt nên việc khiến nó hiểu và thực hiện được việc sửa lỗi chính tả tiếng Việt không cần huấn luyện quá nhiều.


3.2 Đánh giá mô hình sau fine-tune

Mô hình ViT5 gốc chưa có khả năng sửa lỗi chính tả, nó chỉ mới có khả năng hiểu được nghĩa của ngôn ngữ tiếng Việt. Vì vậy khi ta cho một đầu vào là văn bản chính tả, chúng sẽ sinh ra chuỗi bậy. Ví dụ:


- **Input:** tùy bài thuở ng cho bạc và lụa.
- **Output chuẩn:** tùy bậc thưởng cho bạc và lụa.
- **Output của mô hình gốc:** * tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài
tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài
tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài
tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài
tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài tùy bài
- **Output của model đã fine-tune:** tùy bậc thưởng phạt cho bạc và lụa.

Vì vậy, ta sẽ không đánh giá khả năng sửa lỗi của model gốc, mà ta sẽ chỉ đánh giá model đã được fine-tune. Ta sẽ sử dụng độ đo là Character Error Rate (CER) để đánh giá độ lỗi mô hình.

Một số biểu đồ thể hiện kết quả testing của model sau huấn luyện:



Hình 1: Phân phối độ lỗi



Hình 2: Độ lỗi chi tiết ở các test-case

Đánh giá:

- Từ 2 biểu đồ trên, ta thấy độ lỗi của mô hình tương đối ổn định. Ở histogram (hình 1), biểu đồ thể hiện giá trị số lượng câu giảm ổn định theo chiều tăng CER. Ở biểu đồ scatter plot (hình 2), có thể thấy số test-case có độ lỗi nằm dưới đường trung bình khá dày đặc, và số test-case nằm trên đường trung bình thì thưa thớt hơn. Đây là một dấu hiệu tốt, chứng tỏ model đã học và hội tụ đúng hướng.
- Độ lỗi CER trung bình là 0.1044, là một con số ổn. Nó tương đương việc một chuỗi 100 kí tự thì sẽ sửa đúng được khoảng 90 kí tự, và 10 kí tự còn sai.

- Trong số 1423 test-case:
 - Có 161 test-case được sửa lỗi đúng tuyệt đối, tức $CER = 0.0$, chiếm 11.31% tổng số test-case.
 - Có 13 test-case sửa lỗi còn sai nhiều với $CER > 0.5$, chiếm 0.91% tổng số test-case, là con số tương đối nhỏ.
- **Kết lại:** mô hình sau fine-tune tuy chưa phải xuất sắc trong việc sửa lỗi chính tả tiếng Việt, nhưng đã cho thấy sự tiến bộ ngoài mong đợi khi chỉ với 1 epoch train (714 steps), mô hình từ việc không thể sửa lỗi chính tả đã được fine-tune để có thể sửa lỗi chính tả ở mức độ ổn, với độ lỗi trung bình chỉ khoảng 0.1044 CER.